

搭建数据驱动的优惠券精准投放系统

队伍编号：1122

2025.04

摘要

本文基于现有美团业务脱敏数据，以每一用户产生的每单订单为分析单元，采用统计建模方法得到基于用户历史消费、用券特征的优惠券精准投放系统。

优惠券的特征如有效期限、使用门槛等都是连续变量。如果以每个优惠券为单位建模，会引入过多噪声，容易引起模型过拟合。因此，对优惠券基于 K-means 聚类方法分为 5 类，且能保证每类优惠券都有清晰的实际意义。

数据清理也是统计建模的重要一环。本报告将用户的订单记录和相应的历史活跃信息和获券用券情况进行交叉比对，部分成功填补了原先缺失率高达 60% 的优惠券 ID 信息。

特征工程的质量也决定了统计建模的好坏。本文通过提取用以表征用户的购物偏好和用券习惯的若干特征，并基于这些特征，构建了一个多标签分类的优惠券种类预测模型，并使用机器学习工具中的随机森林算法，实现基于数据驱动的个性化优惠券投放。

进一步的预测方法的改进可以对用户特征进一步的挖掘，也可以使用更多机器学习的应用技术。本报告将随着数据更全面地获得以及统计方法进一步的提升而得到持续改进。

1 背景介绍与研究问题

优惠券营销是互联网行业进行获客和提升用户复购的重要手段之一，广泛应用于电商零售和生活服务行业中。经过行业多年实践，优惠券种类繁多，有门槛券、无门槛券，有满减券、折扣券，等等。但是，近年来此类营销手段过度使用，给用户带来的“优惠感”逐渐减弱，在损害用户消费的同时，还降低了商家的营销实效。

在大数据和人工智能时代，基于机器学习的个性化精准投放是一个可行方案。一个数据驱动的精准投放系统基于用户的历史信息例如购物习惯、浏览记录、以及优惠券核销情况，为各类优惠券找到最优群体，从而实现用户和商家的双赢。在前人工智能时代，就有商家出于类似逻辑，通过识别活跃用户和沉睡用户，采用向高价值用户发放高门槛券、向沉睡用户发放低门槛券的方式，获得了商业上的成功。

本商业分析报告根据美团业务数据，通过建模分析预测平台发券后用户的核销使用率，以促进平台和商户更加精准的开展营销投放动作，提升交易转化。另外，在进行数据清理时，发现数据中存在用户薅羊毛的行为，因此本商业分析报告也对潜在业务漏洞进行分析识别。

2 数据说明与描述

该报告基于脱敏后的美团真实业务数据，不涉及用户隐私。数据时间范围是 2023 年 1 月 1 日至 2023 年 6 月 30 日的订单及用户行为数据，共计涉及约 5 万名用户。用户的订单数据、访问各客户端的活跃日期、以及用户获券数据分别存放在三个表格中。

订单数据包括用户 ID、订单 ID、业务线名称、用户支付日期、用户实付交易额、补贴金额。用户活跃数据包括用户 ID 和用户在美国各端（App、小程序等）的活跃日期。用户获券数据包括包括用户在一段时间内通过购买、主动领取和平台主动发放的各类优惠券。在这三个表格中，用户 ID 与用户手机号一一对应，与用户登录哪一个客户端无关，因此是串联这三个表的关键信息。

在对数据进行探索性数据分析时，发现大部分优惠券核销情况不明（见图??）。核销状态变量为 1 表示未使用，为 2 表示已使用，为 3 表示其他。大部分优惠券的核销状态未知，这无疑给数据清理和有效性交叉验证带来了挑战。




图 1: 不同核销情况下的优惠券数量分布




图 2: 组合使用优惠券的订单数量分布

数据中存在组合使用多张优惠券的订单，也有不使用优惠券的订单。有少量订单在单次消费中组合使用多达 5 张不同优惠券，由此可见不同用户对于优惠券的使用习惯差异很大（见图 2）。

3 数据分析与解读

3.1 数据清洗

1. 数据完整性分析

由于在用户订单数据中，有约 60% 的订单记录缺失优惠券编号 (Coupon_id)，而优惠券编号是对应优惠券特征的唯一依据，因此若想利用用户历史行为数据推测其优惠券使用偏好，需要想办法填补出缺失的优惠券编号；否则，直接删去大量缺失优惠券信息的订单记录将损失大量有用信息。

2. 优惠券编号补齐策略

数据清洗的核心在于不同信息表间的交叉验证。这里简要说明我们猜测出优惠券编号的思路。首先将缺失优惠券编号的订单所对应的用户 ID 与用户获券信息进行比对，找出相同用户 ID 下有效期限和该笔订单下单时间吻合的所有优惠券，进而再将该订单的实付金额以及优惠金额与这些候选优惠券的优惠额度和优惠门槛进行比对。

- 如果能找出唯一一个符合上述标准的优惠券，则找到了缺失的优惠券编号。
- 如果能找到多个符合上述标准的优惠券，则随机选取一个优惠券的编号进行填补。
- 如果一个合适的优惠券都没有找到，而且订单显示优惠金额为 0，则认为该订单没有使用优惠券。
- 如果一个合适的优惠券都没找到，而且订单显示优惠金额非 0，则说明无法从现有数据中挖掘出缺失的优惠券编号，因此直接删去该订单。

3.2 潜在系统漏洞及风险识别

在数据清理过程中，发现的一些潜在薅羊毛行为或系统漏洞有：

- 一些用户重复领取同一编号的优惠券，并且在不同的订单中，这些优惠券的优惠额度还存在相当的差异。这是一个潜在的系统漏洞。

- 当一些订单的总金额没有超过优惠券预设门槛时，这些订单仍能够使用这些优惠券，只是优惠金额比预设优惠金额低。假若这种灵活性并非是平台预设的营销行为，则这一现象可以被视为潜在的系统漏洞。
- 有些用户能以稍高于额定优惠的额度使用优惠券，如预设优惠是 32 元，相应订单却能享受 48 元优惠等等。假若这种灵活性并非是平台预设，则这一现象可以被视为潜在的系统漏洞。

3.3 特征工程

1. 对优惠券的聚类

从用户获券信息中可以得知关于优惠券的三个关键特征：优惠券金额、使用门槛价格、以及有效期限。将这三个特征变量做标准化处理后利用标准化后的无量纲量对数据库中的所有优惠券进行 K-means 聚类。通过类内个体相对类中心的平方误差 SSE 随聚类数量 n 增大而减小的情况，选取 $n=5$ （见图 3）。




图 3: 根据优惠券金额、使用门槛价格、有效期限特征对优惠券进行 K-means 聚类

将聚类后的结果进行可视化，容易总结出每类优惠券的主要特点（详见表 1）。结合商业常识，优惠幅度最大的优惠券种类 4 是最少见的，在数据库中只有 188 例；优惠幅度最小的优惠券种类 2 则是最常见的，在数据库中多达 382822 例。可见聚类的效果整体是符合实际的。

表 1: 优惠券各类别对应的主要特点

优惠券编号	数量	主要特点
0	8356	优惠金额高、门槛低、有效期短
1	2432	优惠金额高、门槛高、有效期短
2	382822	优惠金额低、门槛低、有效期短
3	209770	优惠金额低、门槛低、有效期长
4	188	优惠金额高、门槛低、有效期长

在后续报告中,我们定义“不使用优惠券”的订单编号为 5。对于组合使用多张优惠券的订单,如果订单内存在一张编号为 5 的订单,则认为这是由于前期数据清理造成的,从而将其从附属于该订单的优惠券中删除。现在,我们把问题转化为一个多标签分类的机器学习问题。

2. 基于用户历史数据的特征特取

基于用户历史数据提取出的特征反映了用户多方面的消费习惯:

表 2: 基于用户历史购买、活跃记录和获券信息的特征提取

用户特征名称	含义
Num_odrs_bf	在该用户产生该订单之前的订单总笔数
Amt_odrs_bf	在该用户产生该订单之前的订单总金额 (折扣后金额)
Pc_odrs_X_bf	在该用户产生该订单之前,其所产生的在 X 业务线 (Biz code, X=A,B,C,D) 内的订单数占总订单数的比例
Pc_cpn_i_bf	在该用户产生该订单之前,其使用第 i 类优惠券 (i=0,...,5) 的订单数量占总订单数的比例
Rt_odrvst_bf	在该用户产生该订单之前,其产生的总订单数和活跃天数的比值

Num_odrs_bf 反映了用户消费的绝对数量,Amt_odrs_bf 反映了用户消费的总金额,Pc_odrs_X_bf 反映了用户消费的偏好品类, Pc_cpn_i_bf 则反映了用户使用优惠券的偏好,最后 Rt_odrvst_bf 通过将用户消费订单量对其活跃天数求比值,从而能够度量不同活跃程度的用户的消费“决心”:即是否活跃即消费,我们称其为“决心”变量。




图 4: 基于用户历史数据所提取的若干特征的相关矩阵热力图

从相关关系矩阵中看出，“决心”变量 Rt_odrvst_bf ，消费绝对数量 Num_odrs_bf 和消费总金额 Amt_odrs_bf 这三个特征这者存在较强的相关关系。

3. 特殊节日 (春节) 对用户消费的影响

美团在 2022 年底到 2023 年 2 月 5 日，联动平台超百万商户开启“年货节”，投入数亿元补贴，开展“年味送到家”、“新春享美味”等上千场促销活动。因此，考虑使用“下单时间处于年货节期间”这一特征，将特殊节日对用户消费的整体影响纳入模型。

3.4 建立多标签分类模型

综合以上特征工程所得结果，我们将目标转化为实现一个多标签分类任务。整理得到的数据集以用户所下每笔订单为单元，输入变量为基于用户历史数据提取的若干特征（见表 2）和春节哑变量，输出变量为该用户在该笔订单中使用的所有优惠券类型。

3.5 机器学习统计模型表现

本报告采用随机森林机器学习方法对上文所搭建的模型进行训练和评估。首先将由上文特征工程得到的数据集按 8:2 比例随机分为训练集和测试集。在训练集上使用机器学习算法训练，在测试集上对机器学习算法进行评估。

表 3: 在测试集上对随机森林模型评估

优惠券种类	准确率 (Precision)	召回率 (Recall)	F1-score	样本量
0	0.35	0.06	0.11	1549
1	0.11	0.01	0.02	487
2	0.68	0.58	0.63	66847
3	0.64	0.55	0.59	41233
4	0.33	0.05	0.09	37
5	0.73	0.72	0.72	60303
微平均 (Micro Avg)	0.69	0.62	0.65	170456
宏平均 (Macro Avg)	0.47	0.33	0.36	170456
加权平均 (Weighted Avg)	0.69	0.62	0.65	170456
样本平均 (Samples Avg)	0.62	0.62	0.62	170456

类别不平衡:

从样本量一列中可以看出, 类别 2, 3, 5 在数据集中占比非常高, 而类别 0, 1, 4 占比很少, 模型在这些少数类上的表现明显较差, 尤其是召回率 (Recall) 非常低。

该模型以 0.73 的准确率能很好地类别类型 5 的优惠券, 即“用户在该订单中是否使用优惠券”。这背后的原因是现有的用户中大部分不使用优惠券。因此, 该随机森林模型能帮助商家停止海量投放优惠券的策略, 从而提高用户体验。

该模型在类别 2 和 3 上的表现也还不错, 虽然召回率略低于精确率, 但整体 F1 值都在 0.6 左右。优惠券类别 2 和 3 是两类最为常见的优惠券, 类别 2 对应优惠金额低、门槛低、有效期短, 类别 3 对应优惠金额低、门槛低、有效期长。

该模型在类别 0,1 和 4 上的表现很差。例如模型对于类别 1 的召回率仅为 0.06, 意味着模型几乎从不预测这一类别。

宏平均的 F1 值是 0.36, 明显低于加权平均的 0.65), 说明模型的整体性能被大类 (2、3、5) 拉高了, 而在少数类上效果很差。

所以目前的机器学习模型只是在大体上做到了对用户使用优惠券的行为进行预测。要实现精准预测还有很大一段距离。




图 5: 随机森林模型中的特征重要性排列

从随机森林模型的特征重要性排列中可以看出，用户历史订单总金额 Amt_odrs_bf, 用户使用类别 2 和类别 3 优惠券的订单占总订单数的比例 Pc_cpn_2_bf 和 Pc_cpn_3_bf 是前三个最重要的特征。

在实际工作中，还可利用 SHAP (SHapley Additive exPlanations) 对 Random Forest 模型进行评估。限于时间，这里不作展开。

4 商业应用与总结

本报告通过数据清理、特征工程、统计建模步骤，建立了一个精准投放优惠券的智能系统。

搭建基于数据驱动的优惠券精准投放系统，对美团来说是一个非常重要的营销利器，对优惠券的使用也要力争做到精益化，即用最少的投入成本取得最有效的成本，避免大水漫灌的粗放模式。

要做到精益化的优惠券投放，则不仅需要以精确地计量优惠券成本，更要精准地把合适类型的优惠券投放给适合的用户，即最合适的类型和数量精准地投放给确定的用户，这就需要能预测不同的用户使用优惠券的偏好，并基于现有用户数据评估用户的类型和实用优惠券偏好。

美团平台不论是用户规模还是用户行为数据都非常可观，为分析用户行为提供优惠券和精准的营销提供了非常好的基础，本研究初步提供优惠券精准投放的系统模型，为进一步的深化研究奠定了基础，对用户的行为的分析和预测，为进一步的商业应用提供了机会。